😎 Python y Ciencia de Datos

Los datos están en todas partes y desde el nacimiento de la era digital han empezado a crecer exponencialmente. La ciencia de los datos es un campo que lo que intenta hacer es extraer ideas, aportar información útil, etc.

Etapas del análisis de datos:

Las etapas que se distinguen son:

- Etapa 1 ⇒ Detectar el problema: Qué queremos estimar o predecir?
- Etapa 2 ⇒ Obtener y preparar los datos: Qué recursos tenemos?, qué información es relevante? limpiar los datos.
- Etapa 3 ⇒ Explorar los datos: visualizarlos y localizar en los gráficos posibles tendencias, correlaciones o patrones.
- Etapa 4 ⇒ Modelizar y evaluar los datos: crear el modelo con un algoritmo innovador. Evaluar el modelo.
- Etapa 5 ⇒ Comunicar los resultados: Qué resultados hemos obtenido?, Los resultados tienen sentido?

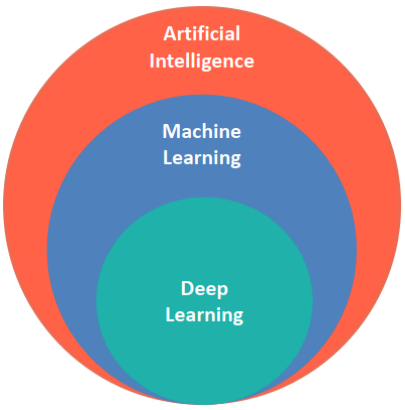

ARTIFICIAL INTELLIGENCE (Inteligencia Artificial)
Ciencia que faculta a las computadoras para imitar la inteligencia humana.

MACHINE LEARNING (Aprendizaje automático)
El Machine Learning es una rama de la Inteligencia Artificial que permite a las máquinas mejorar en una tarea determinada con la experiencia. Es importante aclarar que todas las técnicas de Machine Learning se clasifican como técnicas de Inteligencia Artificial. Sin embargo, no toda la Inteligencia Artificial puede contar como Machine Learning ya que algunos motores básicos basados en reglas pueden ser clasificados como IA pero no aprenden de la experiencia por lo que no pertenecen a la categoría de Machine Learning.

DEEP LEARNING (Aprendizaje Profundo)
El Deep Learning es una rama especializada del Machine Learning que se basa en el entrenamiento de Redes Neuronales Artificiales Profundas usando un gran conjunto de datos como imágenes o textos. Son modelos de procesamiento de información inspirados en el cerebro humano.

	Aprendizaje automático	Aprendizaje profundo
Formato de datos	Datos estructurados	Datos no estructurados
Base de datos	Base de datos manejable	Más de un millón de puntos de datos
Entrenamiento	Se necesita un entrenador humano	El sistema aprende por sí solo
Algoritmo	Algoritmo variable	Red neuronal de algoritmos
Aplicación	Tareas rutinarias sencillas	Tareas complejas
	Algunos ámbitos de aplicación	
	Marketing online	Seguridad de sistemas informáticos
	Atención al cliente	Atención al cliente
	Ventas	Creación de contenidos
	Inteligencia empresarial	Asistentes de voz
	Además de los campos mencionados, ambas tecnologías también se utilizan en muchos otros ámbitos de la vida, como la medicina, la ciencia o la movilidad.	

Machine Learning (Aprendizaje automático)

⇒ Es una rama de la IA cuyo objetivo es desarrollar técnicas que permitan que las computadoras aprendan.
⇒ Es un método de análisis de datos que automatiza la construcción de un modelo analítico.
⇒ Permite a las computadoras encontrar soluciones a problemas, sin ser explícitamente programadas para ello, mediante el uso de algoritmos que aprenden de los datos.

Proceso de Machine Learning

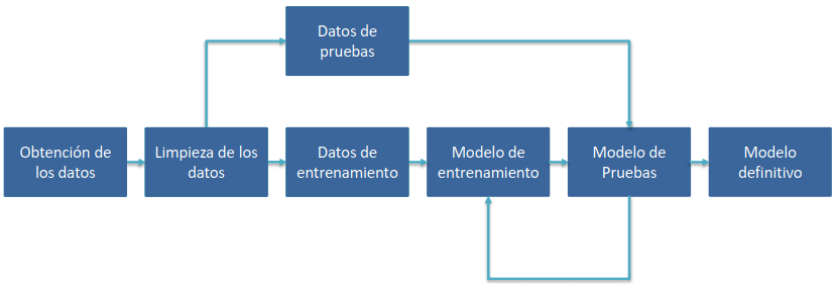

Clasificación

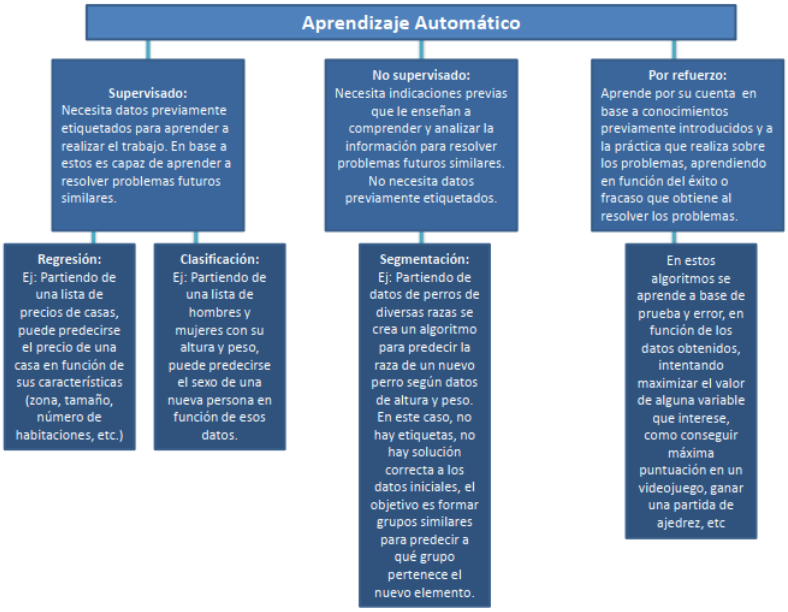

Preprocesado de Datos

Análisis previo de los datos a preprocesar

Se debe analizar la planilla de datos, distinguiendo que nos está mostrando. Para éste ejemplo:

1	Pais,Edad,Salario,Compro
2	Brasil,44,72000,No
3	Argentina,27,48000,Si
4	Chile,30,54000,No
5	Argentina,38,61000,No
6	Chile,40,,Si
7	Brasil,35,58000,Si
8	Argentina,,52000,No
9	Brasil,48,79000,Si
10	Chile,50,83000,No
11	Brasil,37,67000,Si

- 4 columnas: Pais, Edad, Salario y Compro (variables)
- 10 observaciones
- Clientes de una empresa que han comprado un determinado producto.
- Las 3 primeras columnas tienen información personal, origen del cliente, edad y salario.
- La 4ta columna contiene información acerca de cómo ese cliente se relaciona con la empresa (compró o no compró el producto?). Entonces qué diferencia hay entre las variables?

Distinguir variables:

1. Primeras tres columnas: datos que soy capaz de observar, en este caso personas y características, serán las **variable independientes**. Pais, Edad y Salario, forman una matriz que hay que crear.
2. La última columna, Compro, es la que el algoritmo de ML va a intentar predecir a partir de las variables independientes.

> **Las variables independientes son las que suministramos al algoritmo de ML y la variable dependiente es la que se quiere intentar predecir.**

Podría ser una categoría como [Compro] o un número, es decir que con Pais, Edad y Salario intentamos predecir si hubo o no hubo compra.

Importación de los datos

In [1]:
```
import pandas as pd

df = pd.read_csv('archs/Datos.csv')
df
```

Out[1]:

	Pais	Edad	Salario	Compro
0	Brasil	44.0	72000.0	No
1	Argentina	27.0	48000.0	Si
2	Chile	30.0	54000.0	No
3	Argentina	38.0	61000.0	No
4	Chile	40.0	NaN	Si
5	Brasil	35.0	58000.0	Si
6	Argentina	NaN	52000.0	No
7	Brasil	48.0	79000.0	Si
8	Chile	50.0	83000.0	No
9	Brasil	37.0	67000.0	Si

Separación de variables independientes de la variable dependiente

In [2]:
```
X = df.iloc[:, :-1].values
X
```

Out[2]:
```
array([['Brasil', 44.0, 72000.0],
       ['Argentina', 27.0, 48000.0],
       ['Chile', 30.0, 54000.0],
       ['Argentina', 38.0, 61000.0],
       ['Chile', 40.0, nan],
       ['Brasil', 35.0, 58000.0],
       ['Argentina', nan, 52000.0],
       ['Brasil', 48.0, 79000.0],
       ['Chile', 50.0, 83000.0],
       ['Brasil', 37.0, 67000.0]], dtype=object)
```

In [3]:
```
y = df.iloc[:, 3].values
y
```

Out[3]:
```
array(['No', 'Si', 'No', 'No', 'Si', 'Si', 'No', 'Si', 'No', 'Si'],
      dtype=object)
```

Observar que para X ([[]]) devuelve una matriz y para y un vector([])

Valores Desconocidos

Resolver el problema de los datos faltantes

En particular existen *diferentes enfoques* que se pueden llevar a cabo para resolver los **NaN** es decir, decidir qué se debe hacer con esos datos faltantes.

Por ejemplo , en el conjunto de datos original tal cual lo tenemos aquí, podemos ver claramente que faltan dos valores, hay un dato que falta en la columna Edad y luego tenemos una persona de la cual desconocemos su Salario.

```
Pais,Edad,Salario,Compro
Brasil,44,72000,No
Argentina,27,48000,Si
Chile,30,54000,No
Argentina,38,61000,No
Chile,40,,Si
Brasil,35,58000,Si
Argentina,,52000,No
Brasil,48,79000,Si
Chile,50,83000,No
Brasil,37,67000,Si
```

```
>>> print(dataset)
       Pais  Edad  Salario Compro
0    Brasil  44.0  72000.0     No
1  Argentina  27.0  48000.0     Si
2     Chile  30.0  54000.0     No
3  Argentina  38.0  61000.0     No
4     Chile  40.0      NaN     Si
5    Brasil  35.0  58000.0     Si
6  Argentina   NaN  52000.0     No
7    Brasil  48.0  79000.0     Si
8     Chile  50.0  83000.0     No
9    Brasil  37.0  67000.0     Si
```

Cómo detectamos los valores desconocidos o faltantes?

In [4]:
```
df.isnull().values.any()
```

Out[4]:
```
True
```

Devolverá True si hay algún valor NaN en nuestro DataFrame.

In [5]:
```
df.isnull().any()
```

Out[5]:
```
Pais       False
Edad        True
Salario     True
Compro     False
dtype: bool
```

Emite en qué columnas se encuentran nuestros valores NaN.

In [6]:
```
df.isnull().sum().sum()
```

Out[6]:
```
2
```

Emite cuántos NaN tenemos en total.

In [7]:
```
nan_rows = df[df.isnull().any(1)]
nan_rows
```

Out[7]:

	Pais	Edad	Salario	Compro
4	Chile	40.0	NaN	Si
6	Argentina	NaN	52000.0	No

Extrae las filas que contienen valores NaN.

a. Hay que encontrar una mejor solución que el eliminar toda la fila.
b. Una posibilidad, para este caso, es reemplazar el valor desconocido de la columna Edad por la media de todos los valores de la columna de Edad.
c. Con el mismo criterio se resolvería el valor desconocido de la columna Salario.

Instalar: **pip install -U scikit-learn** ⇒ https://scikit-learn.org/stable/ (https://scikit-learn.org/stable/)

In [8]:
```
from sklearn.impute import SimpleImputer
import numpy as np

imputer = SimpleImputer(missing_values = np.nan, strategy="mean")
X[:,1:3]
X
```

Out[8]:
```
array([['Brasil', 44.0, 72000.0],
       ['Argentina', 27.0, 48000.0],
       ['Chile', 30.0, 54000.0],
       ['Argentina', 38.0, 61000.0],
       ['Chile', 40.0, nan],
       ['Brasil', 35.0, 58000.0],
       ['Argentina', nan, 52000.0],
       ['Brasil', 48.0, 79000.0],
       ['Chile', 50.0, 83000.0],
       ['Brasil', 37.0, 67000.0]], dtype=object)
```

In [9]:
```
'''
Utilizamos SimpleImputer para resolver el problema de los NaN
'''
imputer = imputer.fit(X[:,1:3])
X[:,1:3] = imputer.transform(X[:,1:3])
X
```

Out[9]:
```
array([['Brasil', 44.0, 72000.0],
       ['Argentina', 27.0, 48000.0],
       ['Chile', 30.0, 54000.0],
       ['Argentina', 38.0, 61000.0],
       ['Chile', 40.0, 63777.77777777778],
       ['Brasil', 35.0, 58000.0],
       ['Argentina', 38.77777777777778, 52000.0],
       ['Brasil', 48.0, 79000.0],
       ['Chile', 50.0, 83000.0],
       ['Brasil', 37.0, 67000.0]], dtype=object)
```

fit() es utilizado para generar parámetros de modelo de aprendizaje a partir de datos de entrenamiento.

transform(), los parámetros generados a partir del método fit() son aplicados al modelo para generar un conjunto de datos transformado.

Estos métodos se utilizan para **centrar / escalar** características de un dato dado. Básicamente ayuda a normalizar los datos dentro de un rango particular.

Datos categóricos

Tipos de Variables

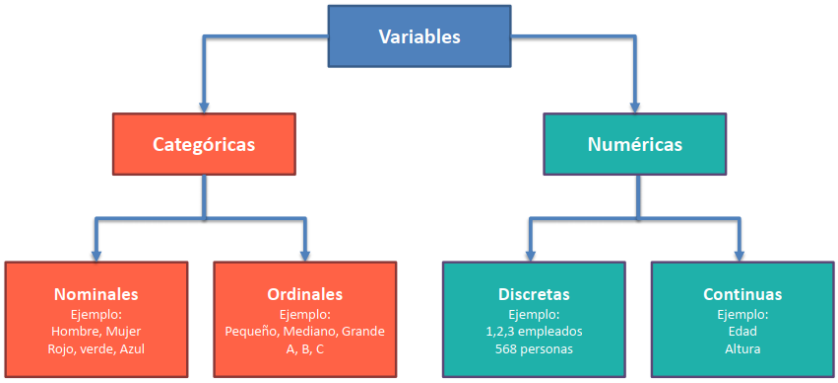

Datos categóricos son las columnas Pais y Compro, observar que no son datos numéricos. Entonces la *primera face* de limpieza es traducir a números estos datos.

In [10]:
```
X
```

Out[10]:
```
array([['Brasil', 44.0, 72000.0],
       ['Argentina', 27.0, 48000.0],
       ['Chile', 30.0, 54000.0],
       ['Argentina', 38.0, 61000.0],
       ['Chile', 40.0, 63777.77777777778],
       ['Brasil', 35.0, 58000.0],
       ['Argentina', 38.77777777777778, 52000.0],
       ['Brasil', 48.0, 79000.0],
       ['Chile', 50.0, 83000.0],
       ['Brasil', 37.0, 67000.0]], dtype=object)
```

In [11]:
```
from sklearn.preprocessing import LabelEncoder
'''
Utilizamos LabelEnconder para convertir a números los datos categóricos.
'''
labelencoder_X = LabelEncoder()
X[:, 0] = labelencoder_X.fit_transform(X[:, 0])
X
```

Out[11]:
```
array([[1, 44.0, 72000.0],
       [0, 27.0, 48000.0],
       [2, 30.0, 54000.0],
       [0, 38.0, 61000.0],
       [2, 40.0, 63777.77777777778],
       [1, 35.0, 58000.0],
       [0, 38.77777777777778, 52000.0],
       [1, 48.0, 79000.0],
       [2, 50.0, 83000.0],
       [1, 37.0, 67000.0]], dtype=object)
```

fit_transform() es una combinación de fit()y transform() en el mismo conjunto de datos.

LabelEncoder() codifica etiquetas de una característica categórica en valores numéricos.

Cualquier modelo tomará esos números en forma ordinal (0 < 1 < 2) pero los países no son comparables. Aparece el concepto de variables dummy o One Hot Encode

Variables Dummy

La introducción de **variables ficticias**, o codificación **One-hot**, es una forma de incluir variables nominales en un modelo de ML.

Supongamos que tenemos una variable nominal que representa una ocupación, con 3 niveles: comerciante, ingeniero y empresario, y deseamos incluir esta variable en nuestro modelo para predecir los ingresos.

Para incluirla en un modelo, hay que convertirla en un número, pero **al ser una variable nominal, no existe un orden natural que podamos utilizar para asignarle un número a cada categoría**. Entonces, podríamos utilizar un mapeo arbitrario?, por ejemplo asignando 1 para comerciante, 2 para ingeniero y 3 para empresario?.

No. Lo que ocurrirá es que después de ajustar el modelo, sin importar el coeficiente que obtenga, los ingresos de ingeniero siempre estarán entre los de comerciante y empresario, por lo tanto el mapeo arbitrario no es una forma adecuada de incluir variables nominales.

La forma correcta de incluir variables nominales es la codificación **One-Hot**. En la codificación One-Hot, **si la variable tiene n niveles, agrega n-1 columnas a la matriz**. En el ejemplo dado, agregaría 2 columnas, porque hay 3 ocupaciones.

La primera columna, supongamos que pertenece a ingenieros. Esa variable tomaría el valor 1 si la persona es un ingeniero, 0 en caso contrario. La segunda columna, digamos comerciante, sería un indicador similar, pero para comerciante.

Estas variables comerciante e ingeniero son las que se denominan **variables ficticias**. **Para cada nivel de la variable nominal, existe una configuración única de variables ficticias**. Hay que tener en cuenta que, si la variable toma el nivel empresario, ambas variables ficticias son cero. **Dos o más variables ficticias no toman el valor 1 simultáneamente**.

En regresión con variables ficticias, ahora hay dos parámetros para la ocupación: el parámetro para comerciante y el parámetro para ingeniero. Estos dos parámetros pueden tomar valores diferentes y, por lo tanto, se considera las variables nominales como desordenadas.

Una pregunta que se podría hacer es, ¿por qué no tres variables ficticias, una para cada ocupación? La respuesta es que, dado que exactamente una de las variables ficticias será 1 para cada persona, la matriz se vuelve singular si ya tiene un término de intersección.

In [12]:
```
X
```

Out[12]:
```
array([[1, 44.0, 72000.0],
       [0, 27.0, 48000.0],
       [2, 30.0, 54000.0],
       [0, 38.0, 61000.0],
       [2, 40.0, 63777.77777777778],
       [1, 35.0, 58000.0],
       [0, 38.77777777777778, 52000.0],
       [1, 48.0, 79000.0],
       [2, 50.0, 83000.0],
       [1, 37.0, 67000.0]], dtype=object)
```

In [13]:
```
from sklearn.preprocessing import OneHotEncoder
from sklearn.compose import make_column_transformer
'''
Utilizamos OneHotEncoder para codificar características categóricas como una matriz numérica
y make_column_transformer permite aplicar transformaciones de datos
de forma selectiva a diferentes columnas del conjunto de datos. Es decir que calcula los datos categóricos
y sobreescribe.
'''
onehotencoder = make_column_transformer((OneHotEncoder(), [0]), remainder = "passthrough")
X = onehotencoder.fit_transform(X)
X
```

Out[13]:
```
array([[0.0, 1.0, 0.0, 44.0, 72000.0],
       [1.0, 0.0, 0.0, 27.0, 48000.0],
       [0.0, 0.0, 1.0, 30.0, 54000.0],
       [1.0, 0.0, 0.0, 38.0, 61000.0],
       [0.0, 0.0, 1.0, 40.0, 63777.77777777778],
       [0.0, 1.0, 0.0, 35.0, 58000.0],
       [1.0, 0.0, 0.0, 38.77777777777778, 52000.0],
       [0.0, 1.0, 0.0, 48.0, 79000.0],
       [0.0, 0.0, 1.0, 50.0, 83000.0],
       [0.0, 1.0, 0.0, 37.0, 67000.0]], dtype=object)
```

In [14]:
```
labelencoder_y = LabelEncoder()
y = labelencoder_y.fit_transform(y)
y
```

Out[14]:
```
array([0, 1, 0, 0, 1, 1, 0, 1, 0, 1])
```

Dividir el dataset

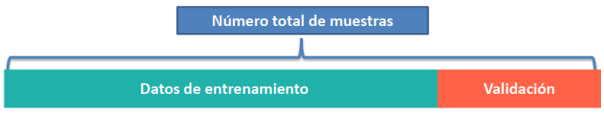

Aproximadamente entre el 70% y 80% del conjunto de datos se utilizará para la fase de entrenamiento, mientras que porcentaje restante será utilizado para evaluar, o sea para la fase de testing, definimos:

- **X_train** es el conjunto de entrenamiento, las **variables independientes** que se utilizarán para entrenar el algoritmo.
- **X_test** datos con los cuales se va a testear que el algoritmo funciona correctamente,
- **y_train** los valores de predicción que también se suministran al algoritmo para que aprenda a predecirlos .
- **y_test** se usa para validar si las predicciones de testing, son o no son correctas, para evaluar la performance, la eficacia del algoritmo.

Posibles problemas:

- **Overfitting o sobre ajuste** ocurre cuando se desempeña bien con los datos de entrenamiento, **pero su precisión es notablemente más baja con los datos de evaluación**, esto se debe a que el modelo ha memorizado los datos que ha visto y no pudo generalizar las reglas para predecir los datos que no ha visto.
- **Underfitting o subajuste** se refiere a un modelo que no puede modelar los datos de entrenamiento, **no puede generalizar a nuevos datos**, esto ocurre cuando el modelo es muy simple.

Dividir el dataset en conjunto de entrenamiento y conjunto de test

In [15]:
```
from sklearn.model_selection import train_test_split
'''
train_test_split permite dividir un dataset en bloques, típicamente bloques
destinados al entrenamiento y validación del modelo.
'''
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2, random_state = 0)
```

In [16]:
```
X_train
```

Out[16]:
```
array([[0.0, 0.0, 1.0, 40.0, 63777.77777777778],
       [0.0, 1.0, 0.0, 37.0, 67000.0],
       [1.0, 0.0, 0.0, 27.0, 48000.0],
       [1.0, 0.0, 0.0, 38.77777777777778, 52000.0],
       [0.0, 1.0, 0.0, 48.0, 79000.0],
       [1.0, 0.0, 0.0, 38.0, 61000.0],
       [0.0, 1.0, 0.0, 44.0, 72000.0],
       [0.0, 1.0, 0.0, 35.0, 58000.0]], dtype=object)
```

In [17]:
```
X_test
```

Out[17]:
```
array([[0.0, 0.0, 1.0, 30.0, 54000.0],
       [0.0, 0.0, 1.0, 50.0, 83000.0]], dtype=object)
```

In [18]:
```
y_train
```

Out[18]:
```
array([1, 1, 1, 0, 1, 0, 0, 1])
```

In [19]:
```
y_test
```

Out[19]:
```
array([0, 0])
```

Escalar los datos

El escalado va a transformar los valores de las características de forma que estén confinados en un rango [a, b], típicamente [0, 1] o [-1, 1].

La normalización va a transformar las características de forma que todas compartan un mismo valor medio y por ejemplo una misma desviación media.

La escala y la normalización a menudo se usan indistintamente. Y para hacer las cosas más interesantes, la escala y la normalización son muy similares.

En **escala**, estamos cambiando el rango de distribución de los datos.

En **normalización**, estamos cambiando la forma de distribución de los datos. El rango es la diferencia entre el elemento más pequeño y el más grande de una distribución.

La escala y la normalización son tan similares que a menudo se aplican indistintamente, pero tienen diferentes efectos en los datos y debemos comprender estas diferencias además, lo que es más importante, saber cuándo aplicar una en lugar de la otra.

En general, es posible que necesitemos escalar datos para problemas de aprendizaje automático de modo que todas las variables tengan un rango de distribución bastante similar para evitar tales problemas.

La normalización es una transformación más radical. El punto de la normalización es cambiar nuestras observaciones para que puedan describirse como una distribución normal. Ver ejemplo (https://towardsai.net/p/data-science/scaling-vs-normalizing-data-5c3514887a84)

En nuestro ejemplo, ocurre que la columna de Edad y la columna de Salario no se encuentran dentro del mismo rango de valores. La diferencia es grande por lo tanto el algoritmo lo tiene que tener en cuenta. La solución a la diferencia es escalar los datos.

Escalar significa normalizar los datos para que estén definidos en el mismo rango de valores, ejemplo típico es escalar entre -1 y 1, de modo que la Edad más pequeña correspondería al valor -1 y la mayor a 1.

Con el Salario (u otras columnas numéricas) es igual, el Salario menor corresponde a -1 y a partir de ahí se escalaría linealmente hasta 1 que representaría el Salario más elevado.

Esta normalización o estandarización es muy importante para evitar que unas variables dominen sobre otras, dentro del algoritmo de ML y que el propio algoritmo pueda discernir que peso le dará a cada una de las variables, no por tener un rango grande o pequeño sino porque aportan en el proceso de predicción o clasificación.

Hay que hacer lo mismo con y train, y_test ? en este caso no, porque lo que se quiere es clasificar compra o no compra. No obstante hay casos, como **la regresión lineal**, donde se recomienda que se realice la normalización del vector de datos a predecir para guardar una consistencia.

In [20]:
```
from sklearn.preprocessing import StandardScaler

sc_X = StandardScaler()
X_train = sc_X.fit_transform(X_train)
X_test = sc_X.transform(X_test)
```

In [21]:
```
X_train
```

Out[21]:
```
array([[-0.77459667, -1.        ,  2.64575131,  0.26306757,  0.12381479],
       [-0.77459667,  1.        , -0.37796447, -0.25350148,  0.46175632],
       [ 1.29099445, -1.        , -0.37796447, -1.97539832, -1.53093341],
       [ 1.29099445, -1.        , -0.37796447,  0.05261351, -1.11141978],
       [-0.77459667,  1.        , -0.37796447,  1.64058505,  1.7202972 ],
       [ 1.29099445, -1.        , -0.37796447, -0.0813118 , -0.16751412],
       [-0.77459667,  1.        , -0.37796447,  0.95182631,  0.98614835],
       [-0.77459667,  1.        , -0.37796447, -0.59788085, -0.48214934]])
```

In [22]:
```
X_test
```

Out[22]:
```
array([[-0.77459667, -1.        ,  2.64575131, -1.45882927, -0.90166297],
       [-0.77459667, -1.        ,  2.64575131,  1.98496442,  2.13981082]])
```

Regresión Lineal Simple

La regresión lineal es un algoritmo de aprendizaje supervisado que se utiliza en Machine Learning y en estadística. Es una aproximación para modelar la relación entre una variable escalar dependiente “y” y una o más variables explicativas “X”. La idea es dibujar una recta que indicará la tendencia del conjunto de datos.

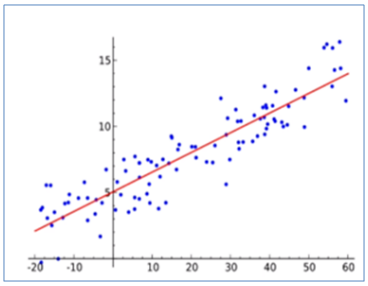

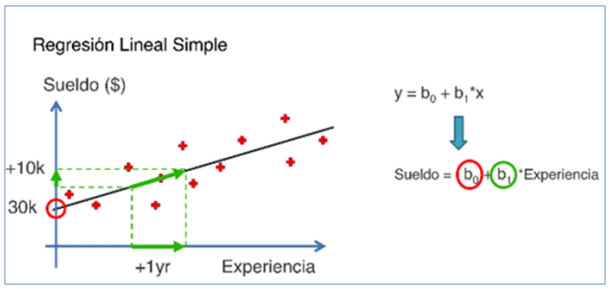

- **b0 sería el sueldo inicial, 30k, y**
- **b1 es el incremento de sueldo que tengo en un año de experiencia, en el ejemplo es 10k**

El algortimo de Regresión Lineal Simple utiliza el método de los mínimos cuadrados para hallar la mejor recta que se ajusta a los datos. Es decir, de todas las rectas se queda con aquella que minimiza los cuadrados de las diferencias entre el dato real y la predicción. Ver explicación (https://www.varsitytutors.com/hotmath/hotmath_help/spanish/topics/line-of-best-fit)

Importación de los datos

In [23]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt

df= pd.read_csv('archs/Datos_de_salarios.csv')
df.head()
```

Out[23]:

	AniosExperiencia	Salario
0	1.1	39343.0
1	1.3	46205.0
2	1.5	37731.0
3	2.0	43525.0
4	2.2	39891.0

In [24]:
```
X = df.iloc[:, :-1].values
y = df.iloc[:, 1].values
df.shape
```

Out[24]: (30, 2)

In [25]:
```
X
```

Out[25]:
```
array([[ 1.1],
       [ 1.3],
       [ 1.5],
       [ 2. ],
       [ 2.2],
       [ 2.9],
       [ 3. ],
       [ 3.2],
       [ 3.2],
       [ 3.7],
       [ 3.9],
       [ 4. ],
       [ 4. ],
       [ 4.1],
       [ 4.5],
       [ 4.9],
       [ 5.1],
       [ 5.3],
       [ 5.9],
       [ 6. ],
       [ 6.8],
       [ 7.1],
       [ 7.9],
       [ 8.2],
       [ 8.7],
       [ 9. ],
       [ 9.5],
       [ 9.6],
       [10.3],
       [10.5]])
```

In [26]:
```
y
```

Out[26]:
```
array([ 39343.,  46205.,  37731.,  43525.,  39891.,  56642.,  60150.,
        54445.,  64445.,  57189.,  63218.,  55794.,  56957.,  57081.,
        61111.,  67938.,  66029.,  83088.,  81363.,  93940.,  91738.,
        98273., 101302., 113812., 109431., 105582., 116969., 112635.,
       122391., 121872.])
```

In [27]:
```
df.describe()
```

Out[27]:

	AniosExperiencia	Salario
count	30.000000	30.000000
mean	5.313333	76003.000000
std	2.837888	27414.429785
min	1.100000	37731.000000
25%	3.200000	56720.750000
50%	4.700000	65237.000000
75%	7.700000	100544.750000
max	10.500000	122391.000000

Aquí tendremos como:

- **variable independiente (X)** o matriz de características, son los años de experiencia por un lado, y
- el sueldo es la **variable dependiente (y)** aquella que el modelo de regresión lineal va a intentar predecir.

Graficamos

In [28]:
```
df.plot(x='AniosExperiencia', y='Salario', style='o')
plt.title('Salario vs Años de Experiencia')
plt.ylabel('Salario')
plt.xlabel('Años de Experiencia')
plt.show()
```

Dividimos en train y test

In [29]:
```
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 1/3, random_state = 0)
```

In [30]:
```
df_aux = pd.DataFrame({'X_train': X_train.flatten(), 'y_train': y_train.flatten()})
df_aux
```

Out[30]:

	X_train	y_train
0	2.9	56642.0
1	5.1	66029.0
2	3.2	64445.0
3	4.5	61111.0
4	8.2	113812.0
5	6.8	91738.0
6	1.3	46205.0
7	10.5	121872.0
8	3.0	60150.0
9	2.2	39891.0
10	5.9	81363.0
11	6.0	93940.0
12	3.7	57189.0
13	3.2	54445.0
14	9.0	105582.0
15	2.0	43525.0
16	1.1	39343.0
17	7.1	98273.0
18	4.9	67938.0
19	4.0	56957.0

Ya tenemos los valores exactos de lo que ganan los individuos, los 20 que formarán parte del proceso de entrenamiento. Con estos datos crearemos el modelo de regresión lineal y luego comprobaremos si el modelo se comporta bien o no, utilizando los elementos de testing.

X_test se suministrará al modelo que se ha creado con los elementos de entrenamiento y miraremos si la predicción que elabora el modelo con estos datos de test se asemeja o no al vector y_test. Es la idea global del algoritmo de regresión lineal simple.

In [31]:
```
df_aux = pd.DataFrame({'X_test': X_test.flatten(), 'y_test': y_test.flatten()})
df_aux
```

Out[31]:

	X_test	y_test
0	1.5	37731.0
1	10.3	122391.0
2	4.1	57081.0
3	3.9	63218.0
4	9.5	116969.0
5	8.7	109431.0
6	9.6	112635.0
7	4.0	55794.0
8	5.3	83088.0
9	7.9	101302.0

In [32]:
```
from sklearn.linear_model import LinearRegression

'''
Con LinearRegression creamos el regresor para el modelo
'''
regression = LinearRegression()
regression.fit(X_train, y_train)
```

Out[32]:
```
LinearRegression()
```

Le damos al modelo los datos de entrenamiento. Entonces, utilizando la técnica de los mínimos cuadrados, basado en la experiencia de aprendizaje, se creó un modelo y este, será capaz de predecir con nuevos años de experiencia que tenga un trabajador en la empresa, cuál es el sueldo que le corresponde.

In [33]:
```
y_pred = regression.predict(X_test)
y_pred
```

Out[33]:
```
array([ 40835.10590871, 123079.39940819,  65134.55626083,  63265.36777221,
       115602.64545369, 108125.8914992 , 116537.23969801,  64199.96201652,
        76349.68719258, 100649.1375447 ])
```

Ahora se pueden predecir las observaciones nuevas, que son las del conjunto de pruebas X_test y que no ha sido utilizado en la creación del modelo lineal.

La función **predict** se encarga de hacer las predicciones.

In [34]:
```
plt.scatter(X_train, y_train, color = "#FF6347")
plt.plot(X_train, regression.predict(X_train), color = "#20B2AA")
plt.title("Sueldo vs Años de Experiencia (Conjunto de Entrenamiento)")
plt.xlabel("Años de Experiencia")
plt.ylabel("Sueldo")
plt.show()
```

In [35]:
```
df_aux = pd.DataFrame({'Actual': y_test.flatten(), 'Predicción': y_pred.flatten()})
df_aux
```

Out[35]:

	Actual	Predicción
0	37731.0	40835.105909
1	122391.0	123079.399408
2	57081.0	65134.556261
3	63218.0	63265.367772
4	116969.0	115602.645454
5	109431.0	108125.891499
6	112635.0	116537.239698
7	55794.0	64199.962017
8	83088.0	76349.687193
9	101302.0	100649.137545

In [36]:

```
plt.scatter(X_test, y_test, color = "#FF6347")
plt.plot(X_train, regression.predict(X_train), color = "#20B2AA")
plt.title("Sueldo vs Años de Experiencia (Conjunto de Testing)")
plt.xlabel("Años de Experiencia")
plt.ylabel("Sueldo")
plt.show()
```

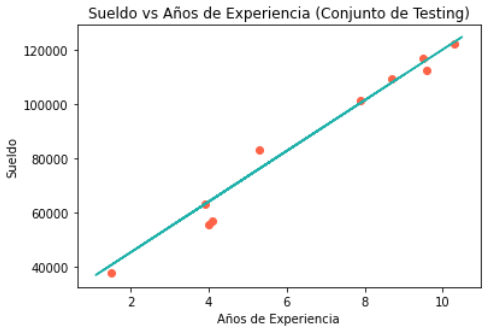

Métricas de evaluación

Para los algoritmos de regresión, se utilizan comúnmente tres métricas de evaluación:

- El error medio absoluto (MAE) es la media del valor absoluto de los errores. Ver MAE (https://es.wikipedia.org/wiki/Error_absoluto_medio)
- El error cuadrático medio (MSE) es la media de los errores al cuadrado. Ver MSE (https://es.wikipedia.org/wiki/Error_cuadr%C3%A1tico_medio)
- Raíz cuadrada del error cuadrático medio (RMSE) es la raíz cuadrada de la media de los errores cuadráticos. Ver RMSE (https://es.wikipedia.org/wiki/Ra%C3%ADz_del_error_cuadr%C3%A1tico_medio)

In [37]:

```
from sklearn import metrics

print('Error Medio Absoluto (MAE):', metrics.mean_absolute_error(y_test, y_pred))
print('Error cuadrático medio (MSE):', metrics.mean_squared_error(y_test, y_pred))
print('Raíz cuadrada del error cuadrático medio (RMSE) :', np.sqrt(metrics.mean_squared_error(y_test, y_pred)))
```

```
Error Medio Absoluto (MAE): 3426.4269374307123
Error cuadrático medio (MSE): 21026037.329511296
Raíz cuadrada del error cuadrático medio (RMSE) : 4585.4157204675885
```

Ejemplo de Regresión Lineal Simple (ejemplos de RL y RLM/ejemplo_de_regresion_lineal_simple.ipynb)

Ejemplo de Regresión Lineal Múltiple (ejemplos de RL y RLM/ejemplo_de_regresion_lineal_multiple.ipynb)

In [ ]:

```

```